Débug, VM et Docker

M1 - CHPS
Architecture Interne des Systèmes d'exploitations (AISE)



Spack

- Conçu pour les problématiques HPC
- Gestionnaire de paquets en userspace
- Supporte de nombreuses recettes HPC:
 - Plusieurs souches MPI
 - hwloc
- Prend en charge les variantes compil' et les flags
- Simple à installer:
 - Télécharger les sources: https://github.com/spack/spack
 - export PATH=\$PWD/spack/bin:\$PATH
 - Intégration: source ./spack/share/spack/setup-env.sh

```
spack
             usage: spack [-hkV] [--color {always, never, auto}] COMMAND ...
   Space A flexible package manager that supports multiple versions,
             configurations, platforms, and compilers.
         Co These are common spack commands:
        Ge query packages:
               list
                                          list and search available packages
                                          get detailed information on a particular package
               info
        Su
               find
                                          list and search installed packages
             build packages:
               install
                                          build and install packages
               uninstall
                                          remove installed packages
                                          show what would be installed, given a spec
               spec
         Pre
→ spack find
==> 85 installed packages
-- linux-linuxmint20-haswell / gcc@9.3.0
autoconf@2.69
                   czmq@4.1.1
                                     gmp@6.2.1
                                                          libmd@1.0.3
                                                                           m4@1.4.19
                                                          libpciaccess@0.16
automake@1.15
                   diffutils@3.7
                                     hwloc@2.5.0
                                                                           mpc@1.1.0
automake@1.16.3
                   diffutils@3.8
                                     hwloc@2.6.0
                                                          libsigsegv@2.13
                                                                           mpfr@3.1.6
automake@1.16.5
                   docbook-xml@4.5
                                     hwloc@2.6.0
                                                          libsodium@1.0.18
                                                                           ncurses@6.2
berkeley-db@18.1.40
                   docbook-xsl@1.79.2
                                     jansson@2.13.1
                                                          libtool@2.4.6
                                                                           numactl@2.0.14
binutils@2.37
                   expat@2.4.1
                                     libbsd@0.11.3
                                                          libxml2@2.9.12
                                                                           openmpi@4.1.1
                   flux-core@0.31.0
                                     libedit@3.1-20210216
boost@1.77.0
                                                          libyaml@0.2.5
                                                                           openssh@8.7p1
bzip2@1.0.8
                   flux-sched@0.20.0
                                     libelf@0.8.13
                                                          libzmg@4.3.4
                                                                           openssl@1.1.1l
                                     libevent@2.1.12
                                                                           openssl@1.1.1l
cmake@3.21.2
                   gcc@9.3.0
                                                          lua@5.3.5
cmake@3.21.4
                   qdbm@1.19
                                     libffi@3.3
                                                          lua-luaposix@35.0
                                                                           osu-micro-benchmarks@5.7.1
cuda@11.4.0
                   gettext@0.21
                                     libiconv@1.16
                                                          lz4@1.9.3
                                                                           pcre@8.44
```

Python & pyenv

- Python est maintenant prédominant en environnement HPC
 - Codage simple pour des non-experts
 - Large panel de fonctionnalités
 - Gestionnaire de paquets inclus
 - Langage orienté objet
 - Python 2 déprécié, focus sur python3!
- Installer un paquet : pip
 - pip install mpi4py (via pypi.org)
 - pip install .

Pyenv

- Toujours essayer de développer dans des « environnements »
- Un environnement crée une installation virtuelle d'une souche Python
- La gestion de l'environnement Python peut être cloisonné
 - Pip install virtualenv
- Créer un env: python3 -m virtualenv ./build
- Charger un env: source ./build/bin/activate
- Décharger: deactivate
- Supprimer un env: rm -rf ./build/
- Comment gérer plusieurs installations Python par dessus !
 - Pyenv!

The Art of Debugging

Bug d'un programme

• Qu'est-ce qu'un « bug » dans un programme?

Bug d'un programme

- Qu'est-ce qu'un programme qui « bug » ?
 - Crash (SEGV par exemple)
 - Résultat différent de ce qui est attendu
 - Interblocage (deadlock)
- Idée : Suivre l'exécution du programme (flot & variables)
- L'outil du débutant en debug : printf
 - Avantages : Simple, aucune connaissance à priori
 - Inconvénients : recompilation, scories...



Le « vrai » debugging

- Contrôlé par un outil tiers : le débugger
- Large panel de fonctionnalités :
 - Suivre une variable
 - Mettre en pause le programme
 - Insérer des « points d'arrêt » (breakpoint)
 - Exécution du programme instruction par instruction
 - Explorer le binaire
 - Explorer la mémoire
 - ...

Exemple d'un debugger

```
☐ gcc <u>segv.c</u> -g && ./a.out
[1] 28842 segmentation fault (core dumped) ./a.out
```



```
Reading symbols from ./a.out...done.
adb >> run
Starting program: /home/adamj/Documents/cours/aise/Cours_5/debug/a.out
Missing separate debuginfos, use: dnf debuginfo-install glibc-2.27-37.fc28.x86_64
Program received signal SIGSEGV, Segmentation fault.
 odItszapc
                                                                   RCX: 0x0
                                                                                         R12:
                       R9 : 0x00007FFFF7DD1D80
                                             R10: 0x
                                                                   R11: 0
                       R14: 0x00000000000000000
                                             R15: 0x00000000000000000
 CS: 0033 DS: 0000 ES: 0000 FS: 0000 GS: 0000 SS: 002B
                                                                             Error while running hook_stop:
Cannot access memory at address 0x0
0x000000000000000000 in ?? ()
adb >> backtrace
#0 0x0000000000000000 in ?? ()
#1 0x00000000004004ac in main (argc=0x1, argv=0x7fffffffda78) at segv.c:4
```



- « GNU Debugger »
- Le debugging n'est pas magique, des informations supplémentaires sont ajoutées au binaire via le flag -g
- Extra informations dans les sections dédiées (voir format DWARF)
- Commande interactive. Un prompt est ouvert en attente de commandes utilisateur (ou d'un script)
- Lancer GDB: gdb ./a.out (ou file ./a.out au prompt)
- Arguments: option --args ou set args au prompt
- Démarrer le programme : run
- Quitter: q[uit] (ou Ctrl + D)
- Aide: help <cmd>
- Spack install gdb

n-tête	es de section :	
[Nr]	Nom	Туре
[0]		NULL
[1]	.interp	PROGBITS
[2]	.note.ABI-tag	NOTE
	.note.gnu.build-i	d NOTE
[4]	.gnu.hash	GNU_HASH
[5]	.dynsym	DYNSYM
[6]	.dynstr	STRTAB
[7]	.gnu.version	VERSYM
[8]	.gnu.version_r	VERNEED
[9]	.rela.dyn	RELA
[10]	.init	PROGBITS
[11]	.text	PROGBITS
	.fini	PROGBITS
[13]	.rodata	PROGBITS
[14]	.eh_frame_hdr	PROGBITS
[15]	.eh_frame	PROGBITS
[16]	.init_array	INIT_ARRAY
[17]	.fini_array	FINI_ARRAY
[18]	.dynamic	DYNAMIC
[19]	.got	PROGBITS
[20]	.got.plt	PROGBITS
[21]	.data	PROGBITS
[22]	.bss	NOBITS
		PROGBITS
[24]	.debug_aranges	PROGBITS
[25]	.debug_info	PROGBITS
[26]	.debug_abbrev	PROGBITS
	.debug_line	PROGBITS
[28]	.debug_str	PROGBITS
		SYMTAB
	.strtab	STRTAB
[31]	.shstrtab	STRTAB

- Afficher du contenu : print (ou p) de tout type. Le type doit être connu de
 GDB pour être affiché. Peut couvrir quasiment toute expression C (ex: a->b.c)
- La variable i : print i
- Le contenu du pointeur p : print *p
- Le contenu à l'adresse (de type T) : print {T}addr
- Rappel : VOID n'est pas un type défini!
- Briser une ambiguïté de portée : print main::i
- Pointer.

 Read as integer, print as character.

 Integer, signed decimal.

 Floating point number.

 Integer, print as octal.

 Try to treat as C string.

 Integer, print as binary (t = "two").

 Integer, unsigned decimal.

 Integer, print as hexadecimal.
- Variables GDB, préfixées par « \$ » : registres, retour de print...

```
qdb >> x $rsp
0x7fffffffdfe8: 0x00007fffff7ddf0b3
gdb >> x/10a $rsp
0x7fffffffdfe8: 0x7fffff7ddf0b3 < libc start main+243> 0x7ffff7ffc620 < rtld global ro>
                                          0x5555555552b0 < libc csu init>
0x7fffffffe008: 0x55555555531 <main>
                                          0x5555555550e0 < start>
qdb \gg x/10zq $rsp
    ffffffdfe8: 0x00007fffff7ddf0b3
                                           0 \times 000007fffffff620
                                           0 \times 0000000100000000
       fffdff8: 0x00007fffffffe0d8
         fe008: 0x00005555555555231
                                           0x00005555555552b0
    ffffffe018: 0xb0c75bfdb89320cb
                                          0x00005555555550e0
0x7fffffffe028: 0x00007fffffffe0d0
                                           0 \times 00000000000000000
```

- Le programme s'exécute comme s'il était hors de GDB. Un deadlock ou un SEGV peut donc se reproduire.
- Pour interrompre le programme pendant son exécution : Ctrl + C
- Principe de base : Une fois le programme stoppé, il est possible d'inspecter son contenu. Lorsqu'un programme est stoppé, il se trouve sur une instruction donnée, mappée dans l'espace mémoire du processus
- Idée : afficher la pile d'appels courante : bt
- Navigation entre les « frames » : up | down | frame #x

```
gdb >>> bt

#0  0x00007ffff7bc78bd in __lll_lock_wait () from /lib64/libpthread.so.0
#1  0x00007ffff7bc0d05 in pthread_mutex_lock () from /lib64/libpthread.so.0
#2  0x000000000040070c in func (arg=0x7fffffffd96c) at threads.c:18
#3  0x00007ffff7bbe594 in start_thread () from /lib64/libpthread.so.0
#4  0x00007ffff78f1f4f in clone () from /lib64/libc.so.6
```

- Il est possible de définir statiquement des instructions où l'on souhaite stopper le programme pour pouvoir l'inspecter : le « point d'arrêt » ou **breakpoint**
- Peut être une adresse mémoire (0x...), un nom de fonction (symbole, par extension) ou un tuple (fichier, numéro de ligne), si l'option -g est passé à la compilation
- À chaque fois que le point d'arrêt est rencontré, le programme est suspendu
- Mettre un breakpoint : break <ref>
- Supprimer un breakpoint : delete <ref>
- Activer / désactiver un breakpoint : enable | disable <ref>
- Reprendre une exécution normale après un breakpoint : continue
- À considérer : les watchpoints (triggers sur changement de contenu)

- Comment régler la question : « Ma fonction est appelée 100 fois, comment mettre un breakpoint seulement sur certaines occurrences ? »
- Idée : Les conditions
- La condition doit toujours être une expression C valide et doit pouvoir être évaluée comme un booléen (vrai/faux)
- Le contexte de la condition est la frame unrollée et non sa parente. Les variables locales sont donc accessibles
- Exemple: break mult if a == 10

- Un breakpoint est souvent posé à priori, sans savoir ou le programme présente un bug. On peut donc se poser la question : « Comment continuer le programme jusqu'au bug tout en inspectant chaque instruction ? »
- Idée : le « pas-à-pas » (= stepping)
- Une fois le breakpoint atteint, il est possible d'avancer bloc par bloc, revenant à mettre un breakpoint sur chaque ligne (=tbreak)
- step: ligne de code suivante (peut prendre un nombre en argument)
- next : ligne de code suivante, sans descendre dans les fonctions appelées
- continue : reprendre une exécution normale
- Pour avoir un grain par instruction, utiliser les versions suffixées par « i » (stepi, nexti...)
- Terminer la fonction courante (jusqu'au return) : finish

- Obtenir des informations: info
- Gestion des signaux : handle
- Quel type de variable ? : whatis
- Code machine? Disassemble

```
gdb >> disassemble /m mult
Dump of assembler code for function mult:
   0 \times 0 0 0 0 0 0 0 0 0 0 0 4 0 0 4 e 6 <+0>:
                                               %rbp
                                      push
                                              %rsp,%rbp
   0 \times 0000000000004004e7 <+1>:
                                      mov
                                              %edi,-0x4(%rbp)
   0 \times 0000000000004004ea <+4>:
                                      mov
   0 \times 0000000000004004ed <+7>:
                                               %esi,-0x8(%rbp)
                                      mov
                   return a * b;
   0 \times 0000000000004004f0 < +10>:
                                               -0x4(%rbp),%eax
                                      mov
   0x00000000004004f3 <+13>:
                                               -0x8(%rbp),%eax
                                      imul
   0 \times 0000000000004004f7 < +17>:
                                               %rbp
                                      pop
   0x000000000004004f8 <+18>:
                                      retq
End of assembler dump.
gdb >>
```

```
gdb >> help info
Generic command for showing things about the program being del
List of info subcommands:
info address -- Describe where symbol SYM is stored
info all-registers -- List of all registers and their contents
info args -- Argument variables of current stack frame
info auto-load -- Print current status of auto-loaded files
info auxv -- Display the inferior's auxiliary vector
info bookmarks -- Status of user-settable bookmarks
info breakpoints -- Status of specified breakpoints (all user-
info checkpoints -- IDs of currently known checkpoints
info classes -- All Objective-C classes
info common -- Print out the values contained in a Fortran COM
info copying -- Conditions for redistributing copies of GDB
info dcache -- Print information on the dcache performance
info display -- Expressions to display when program stops
info exceptions -- List all Ada exception names
info extensions -- All filename extensions associated with a
info files -- Names of targets and files being debugged
info float -- Print the status of the floating point unit
info frame -- All about selected stack frame
info frame-filter -- List all registered Python frame-filters
info functions -- All function names
info guile -- Prefix command for Guile info displays
info handle -- What debugger does when program gets various s
info inferiors -- IDs of specified inferiors (all inferiors i
info line -- Core addresses of the code for a source line
info locals -- Local variables of current stack frame
info macro -- Show the definition of MACRO
info macros -- Show the definitions of all macros at LINESPEC
info mem -- Memory region attributes
info os -- Show OS data ARG
info pretty-printer -- GDB command to list all registered pref
info probes -- Show available static probes
info proc -- Show /proc process information about any running
info program -- Execution status of the program
info record -- Info record options
info registers -- List of integer registers and their contents
info scope -- List the variables local to a scope
info selectors -- All Objective-C selectors
info set -- Show all GDB settings
```

Rappel: Layout de la pile

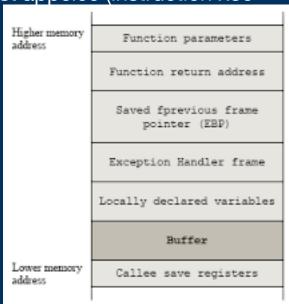
• La pile est une superposition couches appelées « frame », toutes identiques. Une stackframe est créée à chaque fois qu'une nouvelle fonction est appelée (instruction x86

call*)

- Dans une stack-frame est stockée :
 - Les arguments de fonctions
 - L'adresse de retour RIP dans la fonction parente (pour Return Instruction Pointer)
 - Le pointeur de pile RBP de la frame précédente
 - Les variables automatiques (dites « locales »)
- Il existe deux pointeurs de pointeurs de pile
 - RBP : « Base pointer » = l'adresse où commence la frame courante
 - o RSP: « Stack Pointer » = l'adresse <u>qui suit</u> la dernière adresse accessible pour la frame courante

 Manipulation des Registres:

```
gdb >> disas main
Dump of assembler code for function main:
    0x000000000040052e <+0>: push %rbp
    0x000000000040052f <+1>: mov %rsp,%rbp
    0x0000000000400532 <+4>: sub $0x10,%rsp
```



- r* = 64 bits

- e* = 32 bits

- 1* = 16 bits

GDB: Threading

- Un des gros avantages d'un debugger est d'aider à gérer plusieurs flots d'exécution comme les pthreads.
- Lister les threads : info threads
- Par défaut, le thread #0 est celui actif
- Changer de thread: thread #x
- Exécuter une même commande sur plusieurs threads:

```
thread apply #x #y <cmd>
```

- Par défaut, un breakpoint est mis à l'échelle d'un processus
- Un breakpoint thread-specific: break <ref> thread #x if ...
- Attention, un thread doit exister pour être utilisé dans un breakpoint!

GDB: Multi-processing

- Par défaut, GDB ne « suit » pas les processus descendants du processus courant. Configurable via la variable follow-fork-mode
 - O Child: Debug du processus créé
 - Parent: Debug du processus initial (défaut)
- Mais qu'arrive-t-il à l'autre processus ? Configurable via la variable detachon-fork :
 - On : détache le processus non sélectionné (défaut)
 - Off : GDB suit les deux processus. Celui non sélectionné est mis en suspens (défaut)
- Que se passe-t-il si l'application invoque exec*() ? Follow-exec-mode

GDB: Scripting

- Souvent en HPC, il n'est pas possible ou pratique d'avoir un prompt interactif (ex: app avec 64 processus)
- GDB fournit une interface légère de scripting soumis via la ligne de commande : -x
 file | -command=file
- Possible aussi via stdin : gdb < file
- Ou chargeable depuis le prompt : source file
- Prologue:
 - O Set breakpoint pending on : Mise en place de breakpoints sans connaitre le mapping actuel en mémoire. GDB n'avertit pas lorsque le breakpoint n'a pas pu être posé
 - Set pagination off: Éviter la pagination (« Type <return> to continue... »)
 - Set logging on: conserver la sortie (set logging file)
- Epilogue : run

Valgrind

- Spack install valgrind
- Framework d'instrumentation: fournit les méthodes pour permettre à des outils d'analyse dynamiques
- Memcheck: problème de gestion mémoire
 - Accès mémoire invalides
 - Utilisation de mémoire non-initialisée
 - Fuites
 - Double frees & Co
 - Overlap de memcpy

```
==1275213== HEAP SUMMARY:
                in use at exit: 100 bytes in 1 blocks
              total heap usage: 3 allocs, 2 frees, 2,148 bytes allocated
==1275213==
==1275213==
==1275213== 100 bytes in 1 blocks are definitely lost in loss record 1 of 1
==1275213==
               at 0x483B7F3: malloc (in /usr/lib/x86 64-linux-qnu/valgrind/vgpre
==1275213==
               by 0x1092BB: main (in /home/adamj/a.out)
==1275213==
==1275213== LEAK SUMMARY:
==1275213==
               definitely lost: 100 bytes in 1 blocks
               indirectly lost: 0 bytes in 0 blocks
==1275213==
==1275213==
                 possibly lost: 0 bytes in 0 blocks
               still reachable: 0 bytes in 0 blocks
==1275213==
==1275213==
                    suppressed: 0 bytes in 0 blocks
==1275213==
==1275213== For lists of detected and suppressed errors, rerun with: -s
==1275213== ERROR SUMMARY: 1 errors from 1 contexts (suppressed: 0 from 0)
```

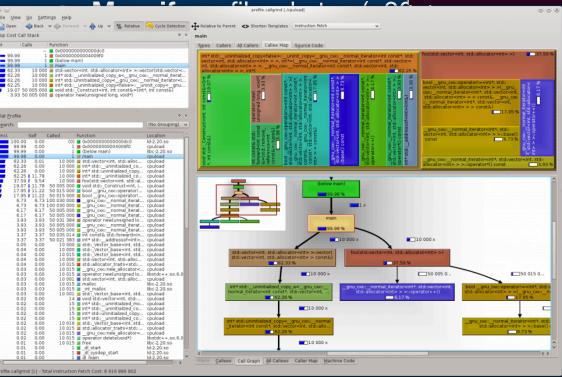
Valgrind

- Mais attention, instrumentation = overhead
- Codes sous memcheck ~20x plus lent
- Cachegrind: profiler d'accès aux caches (~70x)
- Massif: profiler de tas (~20x)
- Callgrind: graphe d'appel
- Helgrind: Threads
- ...
- Certains outils ont une sortie analytique directe, d'autres ont besoin d'outils de visualisation pour être exploitable

Valgrind

- Mais attention, instrumenta
- Codes sous memcheck ~2
- Cachegrind: profiler d'acc

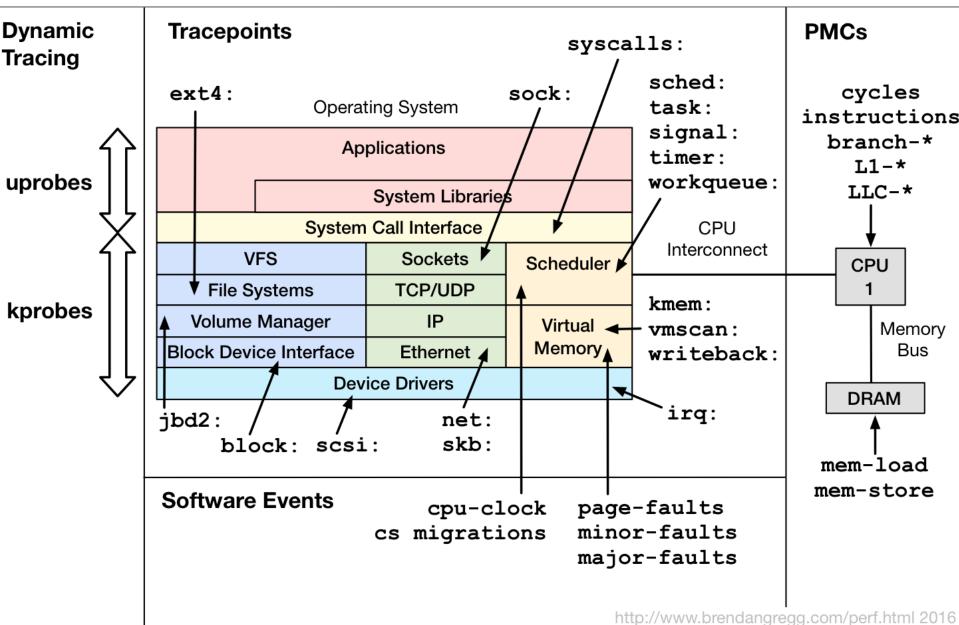




directe, d'autres ont besoin table

- Disponible depuis Linux kernel version 2.6.31
- Trace les compteurs relativement aux piles
- Très utilisé pour compter les cycles d'un app
- Mais peut faire beaucoup plus
- Une seule CLI: « perf »
- Supporte le « tracing » et le « sampling »
 - ⇒yum install perf
 - ⇒apt-get install linux-tools-common linux-tools-generic linux-tools-`uname -r`
 - ⇒git clone https://git.kernel.org/pub/scm/linux/kernel/git/torvalds/ linux.git

Linux perf_events Event Sources



- Se base beaucoup sur ptrace()
- Limitation des processus
- Limitation des capacités allouées par root

```
$ perf record -a
Error:
You may not have permission to collect system-wide stats.

Consider tweaking /proc/sys/kernel/perf_event_paranoid,
which controls use of the performance events system by
unprivileged users (without CAP_SYS_ADMIN).

The current value is 1:

   -1: Allow use of (almost) all events by all users
>= 0: Disallow raw tracepoint access by users without CAP_IOC_LOCK
>= 1: Disallow CPU event access by users without CAP_SYS_ADMIN
>= 2: Disallow kernel profiling by users without CAP_SYS_ADMIN
```

\$perf stat date

Thu May 24 17:44:55 CEST 2018

Stats globales du programme:

```
Performance counter stats for 'date':
         0.889236
                                                           0.311 CPUs utilized
                         task-clock:u (msec)
                         context-switches:u
                                                           0.000 K/sec
                         cpu-migrations:u
                                                           0.000 K/sec
                         page-faults:u
               156
                                                           0.175 M/sec
            452575
                         cycles:u
                                                           0.509 GHz
                                                     # 0.47 insn per cycle
            211872
                         instructions:u
             47041
                         branches:u
                                                          52.900 M/sec
                         branch-misses:u
              4193
                                                           8.91% of all branches
      0.002858312 sec *perf stat -d date Thu May 24 17:46:55 CEST 2018
                        Performance counter stats for 'date':
                                 0.888090
                                               task-clock:u (msec)
                                                                             0.639 CPUs utilized
                                               context-switches:u
                                                                        # 0.000 K/sec
                                        0
                                               cpu-migrations:u
                                                                             0.000 K/sec
                                                                             0.176 M/sec
                                      156
                                               page-faults:u
                                                                             0.000 GHz
                                               cvcles:u
                                   211872
                                               instructions:u
                                    47041
                                               branches:u
                                                                            52.969 M/sec
                                                                        # 8.88% of all branches
                                     4175
                                               branch-misses:u
                                               L1-dcache-loads:u
                                    55889
                                                                            62.932 M/sec
                                               L1-dcache-load-misses:u
                                     6000
                                                                            10.74% of all L1-dcache hits
                          <not supported>
                                               LLC-loads:u
                          <not supported>
                                               LLC-load-misses:u
                              0.001389281 seconds time elapsed
```

Plusieurs exécutions pour lisser le bruit: -r <rep>

```
Performance counter stats for 'date' (1000 runs):
        0,285749
                       task-clock (msec)
                                                      0,643 CPUs utilized
                                                                                      (+-0,06\%)
                                                                                       +- 0,18%)
                                                      0,007 M/sec
                       context-switches
                0
                       cpu-migrations
                                                      0.000 K/sec
                       page-faults
              186
                                                      0,651 M/sec
                                                                                            0.00\%
          855 254
                       cycles
                                                      2,993 GHz
                                                                                           1,39%
                                                                                                     (0,00\%)
                                                      0,95 insn per cycle
                                                                                           0,04%
          810 631
                       instructions
          158 770
                                                 # 555,629 M/sec
                       branches
                                                                                           0,03%
            6 739
                                                      4,24% of all branches
                                                                                           0.07%
                       branch-misses
          216 810
                                                 # 758,743 M/sec
                                                                                           0,03%
                       L1-dcache-loads
    <not counted>
                       L1-dcache-load-misses
                                                                                       +- 4,20%)
                                                                                                     (23,72\%)
                       LLC-loads
                                                                                      (0.00\%)
    <not counted>
                       LLC-load-misses
                                                                                      (0.00\%)
    <not counted>
     0,000444485 seconds time elapsed
                                                                                (+-0,11\%)
```

perf list

• Liste les évènements disponibles:

```
$ perf list -v # List all events you can use (-v for verbose desc.)
```

- \$ perf list -v float # List all events linked to FP operations
- \$ perf list -v | 13 # List all events linked to the L3 cache

perf record

Récupère les stats d'un code

```
$ perf record -g date # Record cycles for « date »
« -g » capture les call stacks
```

Résultats dans « perf.data »

```
$perf record -g -e L1-dcache-load-misses date
```

Selection d'events avec « -e », il vaut mieux limiter leur nombre pour éviter un salin trop important

perf report

- \$ perf record -g date
- \$ perf report --stdio --sort parent

```
100.00% 100.00% [other]
          --37.76%--_dl_sysdep_start
                    dl_main
                     --29.08%-- dl relocate object
                               _dl_lookup_symbol_x
         |--20.32%-- dl addr
          --20.32%--0x2342
          --13.85%--0x1c33a
                    _dl_map_object
                    open path
                    open_verify
         I--4.46%--strlen
          --2.05%--_dl_start_user
                    _dl_start
                    async_page_fault
          --1.06%--_dl_start
                     --0.75%--async page fault
```

perf report « lulesh »

```
$ perf record -e cycles -g ./lulesh2.0 -i 50
$ perf report -g --sort parent
```

```
Samples: 3K of event 'cycles:u', Event count (approx.): 3025875782
 Children
               Self Parent symbol
- 100,00% 100,00% [other]
  - 97,10% libc start main
     -96,24\% main
        - 39,13% LagrangeNodal
             0xffffffffb8b17760
          10,52% CalcKinematicsForElems
          2,86% cbrt
          2,83% CalcElemVolume
          0,57% ldexp
          0,55% std::vector<double, std::allocator<double> >::resize
       0,80% __memset_sse2
  - 0,88% 0x6874697728206c6c
       poll init
       0x19d7000
       opal hwloc base get topology
       hwloc topology load
     - hwloc discover
        - 0,84% hwloc look pci
           - 0,60% pci device get device name
                find device name
```

perf report « lulesh »

\$ perf report -g --sort parent --stdio

```
--97.10%--__libc_start_main
             --96.24%--main
                        --39.13%--LagrangeNodal
                                    --2.05%--0xffffffffb8b17760
                        --10.52%--CalcKinematicsForElems
                        --2.86%--_cbrt
                        --2.83%--CalcElemVolume
                        --0.57%--__ldexp
                        --0.55%--std::vector<double, std::allocat
            --0.80%-- memset sse2
--0.88%--0x6874697728206c6c
          poll_init
           0x19d7000
          opal_hwloc_base_get_topology
hwloc_topology_load
hwloc_discover
            --0.84%--hwloc_look_pci
                        --0.60%--pci_device_get_device_name
                                   find device name
```

perf top

```
$ yes > /dev/null&
[1] 13755
$ perf top -p 13755
```

```
Samples: 94K of event 'cycles:u', Event count (approx.): 53656556765
Overhead Shared Object
                            Symbol
                                 IO_file_xsputneaGLIBC 2.2.5
  32.84% libc-2.17.so
          libc-2.17.so
                                fputs unlocked
          libc-2.17.so
                                 __strlen_sse2
          libc-2.17.so
                                       mempcpy
                                0x00000000000015af
         yes
         yes
                                0x00000000000015c5
          yes
                                 0x00000000000015a0
                                0x00000000000012f0
         yes
          yes
                                0×0000000000001590
          yes
                                0x0000000000001628
                                0x000000000000159c
         yes
         yes
                                0x00000000000015c8
  0,39%
         yes
                                0x0000000000001595
  0,39%
         yes
                                0x00000000000015d5
  0.38%
                                0x000000000000162f
          ves
  0.04% libc-2.17.so
                                _IO_do_write@@GLIBC_2.2.5
For a higher level overview, try: perf top --sort comm,dso
```

Trace de programme en temps réel

perf top -a

```
# perf top -a -e syscalls:sys_enter_open
Trace global (à l'échelle du système) du syscall open (kernel tracepoint)
```

REQUIRES ROOT

```
syscalls:sys enter accept4
                                                    Tracepoint event
syscalls:sys enter access
                                                    Tracepoint event
syscalls:sys enter acct
                                                    [Tracepoint event]
syscalls:sys enter add key
                                                    [Tracepoint event]
syscalls:sys enter adjtimex
                                                    Tracepoint event
syscalls:sys enter alarm
                                                    [Tracepoint event]
syscalls:sys enter bind
                                                    [Tracepoint event]
syscalls:sys enter brk
                                                    Tracepoint event
syscalls:sys enter capget
                                                    [Tracepoint event]
syscalls:sys enter capset
                                                    [Tracepoint event]
syscalls:sys enter chdir
                                                    Tracepoint event
syscalls:sys enter chmod
                                                    [Tracepoint event]
syscalls:sys enter chown
                                                    [Tracepoint event]
syscalls:sys enter chroot
                                                    Tracepoint event
syscalls:sys enter clock adjtime
                                                    [Tracepoint event]
syscalls:sys enter clock detres
                                                    [Tracepoint event]
```

Perf est **beaucoup** plus performant en root, car un grand nombre d'events ne sont disponibles qu'avec un utilisateur privilégié

Perf et programmes MPI

Perf est orienté processus. Pour fonctionner avec un code MPI, il est nécessaire de séparer la sortie dans des fichiers séparés. Ici, un simple script fait l'affaire.

```
#!/bin/sh
H=`hostname`
P=$$
perf record -o perf-${H}-${P}.data $@

$ srun -n 8 script.sh -g ./matmult
$ perf report -i <one-perf-file>.data -g
```

Machines Virtuelles

Virtualisation

Une machine virtuelle:

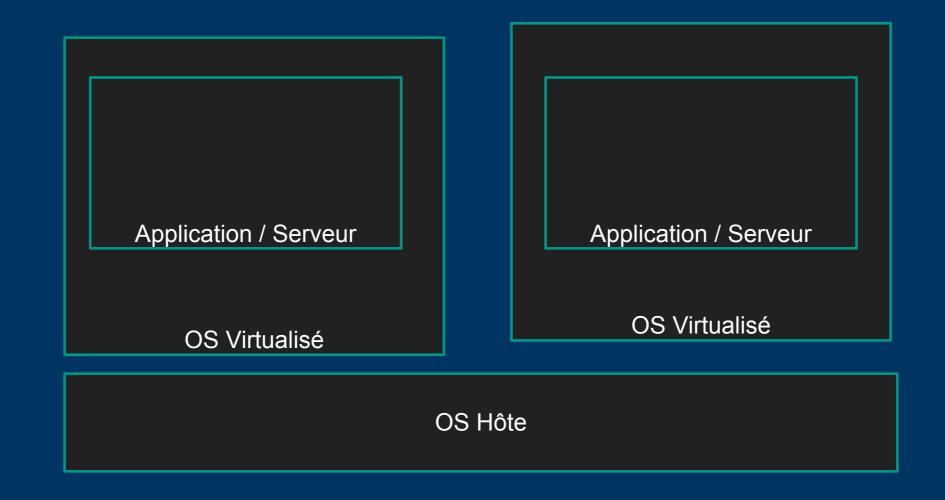
- Émule une machine de manière logicielle pour permettre l'exécution isolée d'un programme;
- Execute du code dans un contexte spécifique (souvent avec l'aide du matériel) pour le contraindre en terme d'accès;



Virtualisation

Une machine virtuelle:

- Émule une machine de manière logicielle pour permettre l'exécution isolée d'un programme;
- Execute du code dans un contexte spécifique (souvent avec l'aide du matériel) pour le contraindre en terme d'accès;



Avantages de la Virtualisation

- Regroupement des serveurs sur une même machine. De plus certains serveurs sont faibles en consommation CPU.
- Isolation FORTE des serveurs avec des systèmes d'exploitation différents et des systèmes de fichiers distincts;
- Isolation y compris vis à vis du matériel (carte réseau virtuelle) et contraintes mémoire cpu explicite (exposition partielle des resources) gestion dynamique des resources (CPU Hotplug);
- Réplication et sauvegarde facilitée (on sauve l'image disque dans sa totalité), rétablir le système c'est rétablir une image plus récente;
- Facilité d'administration il devient possible de migrer un serveur/service donné.

Inconvénients de la Virtualisation

- Les abstractions matérielles ont un coût en performance non négligeable;
- L'OS est totalement répliqué en stockage et en mémoire dans les différentes VMs;
- Si un serveur avec de nombreuses VMs tombe toutes les VMs associées sont inopérantes (besoin de redondance);
- Il y a un overhead d'administration important du fait de la complexité additionnelles des machines séparées.

Image Debian avec Docker

Récupérez une image avec debian:

root MDP toto chps MDP toto

https://france.paratools.com/chps.qcow2

CTRL+ALT pour sortir la souris

Le Conteneur

Conteneurs?

- C'est beaucoup de chose, cela veut principalement dire que les ressources d'un processus sont isolées;
- Ceci utilise la notion de namespace:
 - → Mount namespaces
 - → User-namespaces
 - → Network namespaces
 - **→** (…)
- En général le conteneur consiste en un changement de système de fichier tout en gardant le même noyau à la différence d'une VM par exemple.

Liste des Namespaces

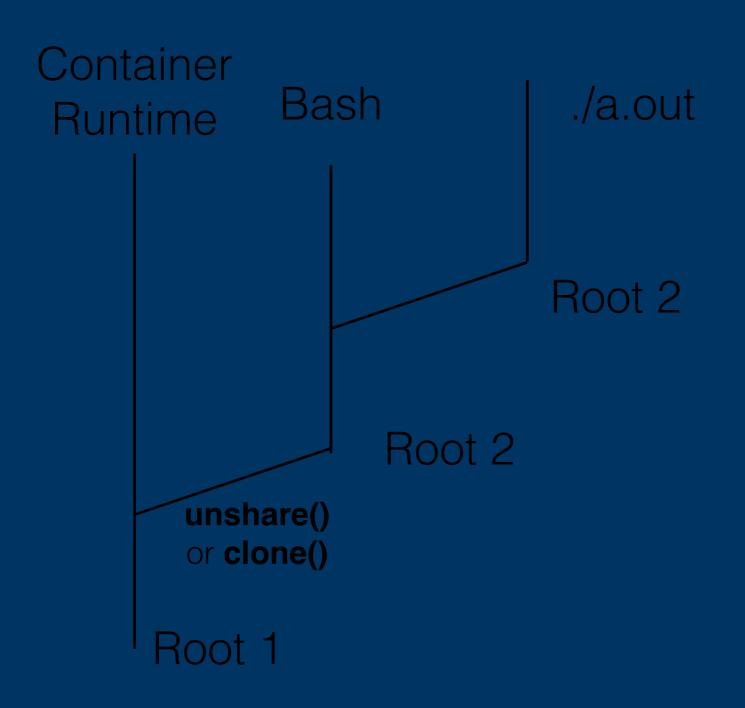
« man namespaces »

Tableau 1

Namespace	Constant	Isolates	
Cgroup	CLONE_NEWCGROUP	Cgroup root directory	
IPC	CLONE_NEWIPC	System V IPC, POSIX message queues	
Network	CLONE_NEWNET	Network devices, stacks, ports, etc.	
Mount	CLONE_NEWNS	Mount points	
PID	CLONE_NEWPID	Process IDs	
User	CLONE_NEWUSER	User and group IDs	
UTS	CLONE_NEWUTS	Hostname and NIS domain name	

Un Conteneur

Aspects Runtime



Le Conteneur vu de l'utilisateur

RUN <IMAGE> <COMMAND>

RUN < IMAGE>

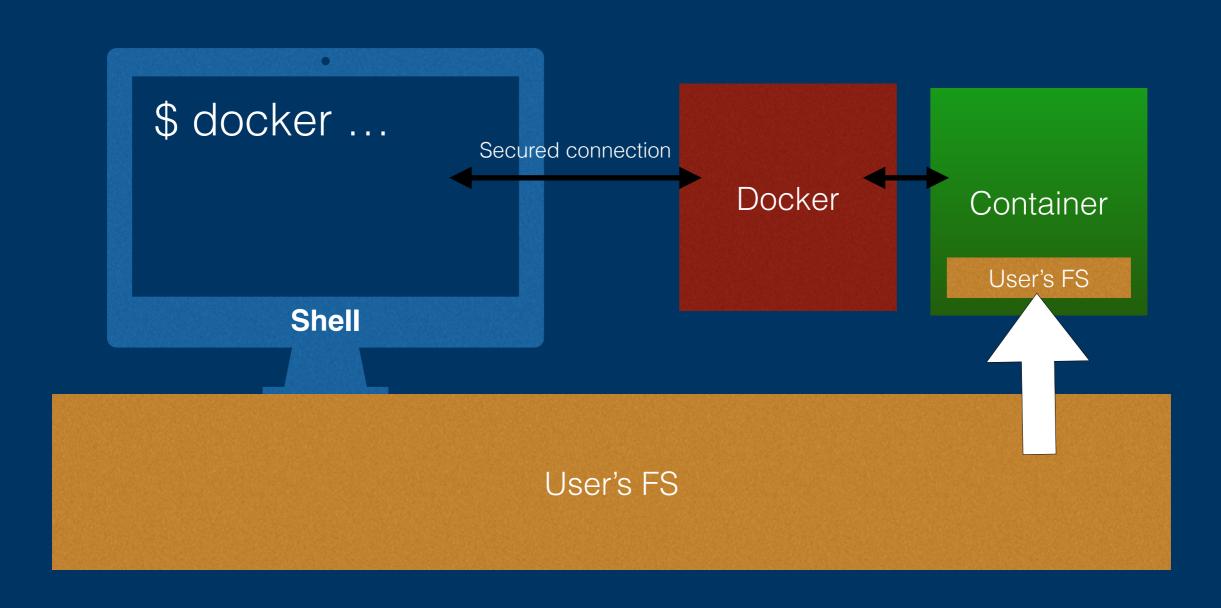
Une image contient toutes les dépendances pour lancer un programmes (binaires bibliothèques ...) mais PAS le kernel.

Docker

Commencer avec Docker

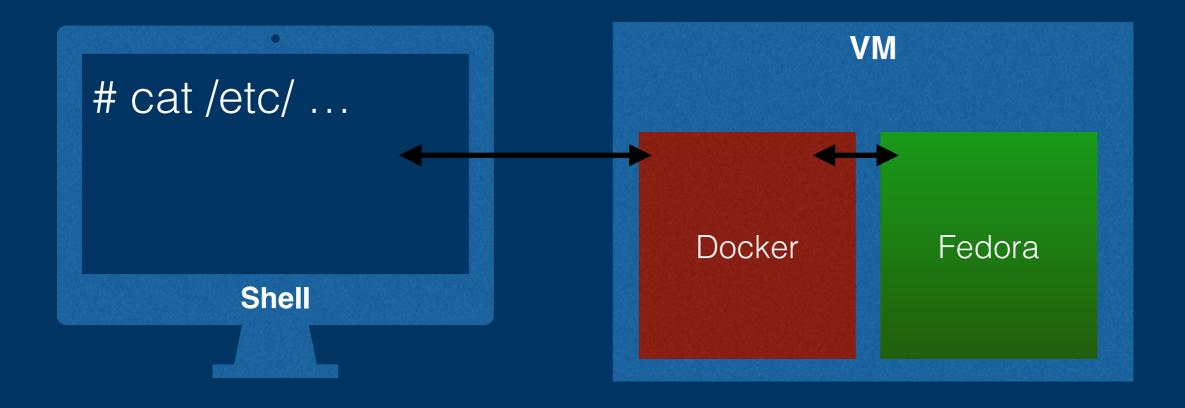
```
$ docker version
Client: Docker Engine - Community
Version: 18.09.5
(...)
```

Le Démon Docker



First Run inside Docker

```
$ docker run -ti fedora
(Entering container ...)
# cat /etc/redhat-release
Fedora release 31 (Thirty One)
```



Syntaxe Docker Run

```
docker run -ti --rm [IMAGE] [COMMAND] [ARGS]
```

- ▶-i : mode interactif (par défaut Docker tourne en arrière plan);
- ▶-t: pour ouvrir un TTY et donc avoir un support terminal complet pour VIM par exemple;
- --rm: supprimer le conteneur à la sortie du programme.

Lister les Images Docker

Pour voir les images disponibles allez sur Docker HUB https://hub.docker.com/search?q=&type=image

```
$ docker image list
```

```
REPOSITORY TAG IMAGE ID CREATED SIZE debian latest b5d2d9b1597b 11 days ago 114MB alpine latest cc0abc535e36 2 weeks ago 5.59MB ubuntu latest 549b9b86cb8d 2 weeks ago 64.2MB fedora latest f0858ad3febd 2 months ago 194MB
```

Lister les Conteneurs

REPOSITORY TAG jupyter/scipy-notebook latest pcocc/umoci v0.1 pcocc/umoci v0.1-amd64 pcocc/tzdata v0.1 pcocc/tzdata v0.1-amd64 pcocc/squashfs-tools v0.1 pcocc/squashfs-tools v0.1-amd64 (...)

\$ docker image list

IMAGE ID CREATED SIZE 3.45GB 2 days ago 295a5802d799 7 months ago 27530b76a409 11.5MB 27530b76a409 7 months ago 11.5MB 7 months ago 4a126134da60 1.53MB 4a126134da60 7 months ago 1.53MB 7 months ago 0da08da32ae5 2.11MB 7 months ago 0da08da32ae5 2.11MB

Lancer un Conteneur Détaché

```
$ docker run -ti -d --rm ubuntu sleep 10000
$ docker ps
CONTAINER ID
                  IMAGE
                                COMMAND
                                                  CREATED
                                                                   STATUS
                                                                                  PORTS
                                                                                                 NAMES
8aa628c5982a
                 ubuntu
                               "sleep 100000"
                                               About a minute ago Up About a minute
                                                                                              recursing_herschel
$ docker attach recursing_herschel
#CTRL + p puis CTRL + q
read escape sequence
```

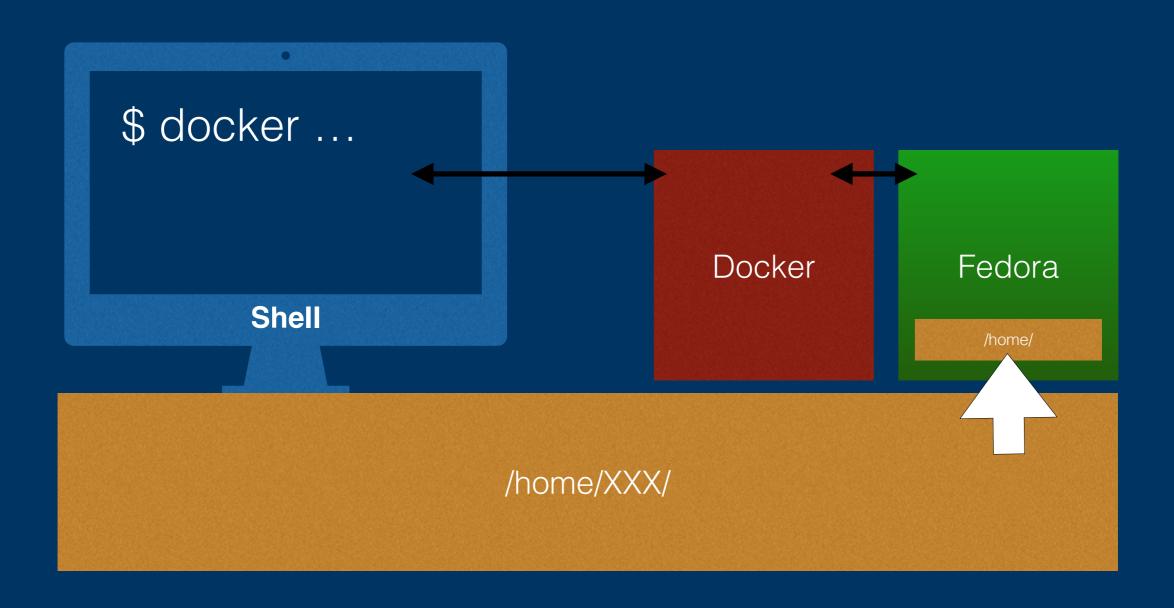
Pour se détacher CTRL+p puis CTRL+q Uniquement si lancé avec -ti !!!!

Monter le \$HOME

```
cd $HOME; touch ./hello_docker
docker run -ti \
    --rm -v $HOME:/home -w /home fedora
ls ./hello_docker
./hello_docker
```

- ►-v : Volume (mounting dir & files) [FROM]:[TO]
- -w: work directory (the CWD of the command being run) here bash by default.

Monter le \$HOME



Voir la Commande par Défaut

\$ docker inspect nginx

```
"Env": [
    "PATH=/usr/local/sbin:/usr/local/bin:/usr/sbin:/usr/bin:/sbin:/bin",
    "NGINX_VERSION=1.17.0",
    "NJS_VERSION=0.3.2",
    "PKG_RELEASE=1~stretch"
],
"Cmd": [
    "/bin/sh",
    "-c",
    "#(nop) ",
    "CMD [\"nginx\" \"-g\" \"daemon off;\"]"
],
```

Altérer la Commande par Défaut

```
$ docker run [OPTIONS] IMAGE[:TAG] [COMMAND] [ARG...]
$ docker run -ti --rm nginx [CMD] [ARGS]
$ docker run -ti --rm nginx /bin/bash
$ docker run -ti --rm nginx /bin/bash
root@2fa50e296016:/#
Exit ou CTRL + D pour quitter
```

Editer une image existante

```
$ docker run -ti \
    --name mycont -v $HOME:/home/ fedora
cp /home/my_data /data
CTRL+D
```

\$ docker ps -a #-a for terminated cont.

CONTAINER ID IMAGE COMMAND CREATED STATUS PORTS NAMES

044ed20ab55b fedora « /bin/bash" 32 seconds ago Exited (0) 20 seconds ago hungry_rosalind

\$ docker commit hungry_rosalind myfed

CONTAINER ID IMAGE COMMAND CREATED STATUS PORTS NAMES

044ed20ab55b fedora « /bin/bash" 32 seconds ago Exited (0) 20 seconds ago hungry_rosalind

\$ docker image list

REPOSITORY myfed fedora

TAG latest latest IMAGE ID 93006aa38912 f0858ad3febd

CREATED
7 seconds ago
2 months ago

SIZE 194MB 194MB

Lancer un Serveur

docker run -ti --rm -p 8080:80 nginx

Redirige 8080 vers le port 80 du conteneur.

```
$ docker run -d -p 8080:80 nginx

$ curl localhost:8080
(...)
<title>Welcome to nginx!</title>
(...)

$ docker ps
CONTAINER ID IMAGE COMMAND PORTS NAMES
2211a94ebf61 nginx "nginx -g 'daemon of..." 0.0.0.0:8080->80/tcp magical_nash
$ docker kill magical_nash
```

Dockerfile Créez vos propre conteneurs

Le Dockerfile

- Décrit la recette d'un conteneur
- Vise à être reproductible (partager la recette et non le conteneur)
- Est la base du partage sur le HUB Docker:

1	ADD file in /	24.65 MB
2	CMD ["bash"]	0 B
3	LABEL maintainer=NGINX Docker Maintainers	0 B
4	ENV NGINX_VERSION=1.17.8	0 B
5	ENV NJS_VERSION=0.3.8	0 B
6	ENV PKG_RELEASE=1~buster	0 B
7	/bin/sh -c set -x	22.72 MB
8	/bin/sh -c ln -sf /dev/stdout	202 B
9	EXPOSE 80	0 B
10	STOPSIGNAL SIGTERM	0 B
11	CMD ["nginx" "-g" "daemon	0 B

FROM

```
FROM [--platform=<platform>] <image> [AS <name>]
Or

FROM [--platform=<platform>] <image>[:<tag>] [AS <name>]
Or
```

FROM [--platform=<platform>] <image>[@<digest>] [AS <name>]

The FROM instruction initializes a new build stage and sets the *Base Image* for subsequent instructions. As such, a valid Dockerfile must start with a FROM instruction. The image can be any valid image – it is especially easy to start by **pulling an image** from the *Public Repositories*.

- ARG is the only instruction that may precede FROM in the Dockerfile. See Understand how ARG and FROM interact.
- FROM can appear multiple times within a single Dockerfile to create multiple images or use one build stage as a dependency for another. Simply make a note of the last image ID output by the commit before each new FROM instruction. Each FROM instruction clears any state created by previous instructions.
- Optionally a name can be given to a new build stage by adding AS name to the FROM instruction. The name can be used in subsequent FROM and COPY —

 from=<name|index> instructions to refer to the image built in this stage.
- The tag or digest values are optional. If you omit either of them, the builder assumes a latest tag by default. The builder returns an error if it cannot find the tag value.

The optional —platform flag can be used to specify the platform of the image in case FROM references a multi-platform image. For example, linux/amd64, linux/arm64, or windows/amd64. By default, the target platform of the build request is used. Global build arguments can be used in the value of this flag, for example automatic platform ARGs allow you to force a stage to native build platform (—platform=\$BUILDPLATFORM), and use it to cross-compile to the target platform inside the stage.

RUN

RUN has 2 forms:

- RUN <command> (shell form, the command is run in a shell, which by default is /bin/sh -c on Linux or cmd /S /C on Windows)
- RUN ["executable", "param1", "param2"] (exec form)

The RUN instruction will execute any commands in a new layer on top of the current image and commit the results. The resulting committed image will be used for the next step in the Dockerfile.

Layering RUN instructions and generating commits conforms to the core concepts of Docker where commits are cheap and containers can be created from any point in an image's history, much like source control.

The *exec* form makes it possible to avoid shell string munging, and to RUN commands using a base image that does not contain the specified shell executable.

The default shell for the shell form can be changed using the SHELL command.

In the *shell* form you can use a \ (backslash) to continue a single RUN instruction onto the next line. For example, consider these two lines:

```
RUN /bin/bash -c 'source $HOME/.bashrc; \
echo $HOME'
```

Together they are equivalent to this single line:

RUN /bin/bash -c 'source \$HOME/.bashrc; echo \$HOME'

EXPOSE

EXPOSE <port> [<port>/<protocol>...]

The EXPOSE instruction informs Docker that the container listens on the specified network ports at runtime. You can specify whether the port listens on TCP or UDP, and the default is TCP if the protocol is not specified.

The EXPOSE instruction does not actually publish the port. It functions as a type of documentation between the person who builds the image and the person who runs the container, about which ports are intended to be published. To actually publish the port when running the container, use the -p flag on docker run to publish and map one or more ports, or the -P flag to publish all exposed ports and map them to high-order ports.

By default, EXPOSE assumes TCP. You can also specify UDP:

EXPOSE 80/udp

To expose on both TCP and UDP, include two lines:

EXPOSE 80/tcp EXPOSE 80/udp

\$ docker run -d -P nginx

\$ docker ps

CONTAINER ID IMAGE bdc0d96b31b7 nginx

COMMAND

CREATED "nginx -g 'daemon of..." 14 seconds ago

STATUS Up 13 seconds

PORTS

NAMES

0.0.0.0:32768->80/tcp boring brattain

ENV

```
ENV <key> <value>
ENV <key>=<value> ...
```

The ENV instruction sets the environment variable <key> to the value <value>. This value will be in the environment for all subsequent instructions in the build stage and can be replaced inline in many as well.

The ENV instruction has two forms. The first form, ENV <key> <value>, will set a single variable to a value. The entire string after the first space will be treated as the <value> - including whitespace characters. The value will be interpreted for other environment variables, so quote characters will be removed if they are not escaped.

The second form, ENV <key>=<value> ..., allows for multiple variables to be set at one time. Notice that the second form uses the equals sign (=) in the syntax, while the first form does not. Like command line parsing, quotes and backslashes can be used to include spaces within values.

For example:

```
ENV myName="John Doe" myDog=Rex\ The\ Dog \
    myCat=fluffy
and
ENV myName John Doe
ENV myDog Rex The Dog
ENV myCat fluffy
will yield the same net results in the final image.
```

The environment variables set using ENV will persist when a container is run from the resulting image. You can view the values using docker inspect, and change them using docker run --env <key>=<value>.

COPY

COPY has two forms:

- COPY [--chown=<user>:<group>] <src>... <dest>
- COPY [--chown=<user>:<group>] ["<src>",... "<dest>"] (this form is required for paths containing whitespace)

The COPY instruction copies new files or directories from <src> and adds them to the filesystem of the container at the path <dest>.

Multiple <src> resources may be specified but the paths of files and directories will be interpreted as relative to the source of the context of the build.

ADD

ADD has two forms:

- ADD [--chown=<user>:<group>] <src>... <dest>
- ADD [--chown=<user>:<group>] ["<src>",... "<dest>"] (this form is required for paths containing whitespace)

The ADD instruction copies new files, directories or remote file URLs from <src> and adds them to the filesystem of the image at the path <dest>.

Multiple <src> resources may be specified but if they are files or directories, their paths are interpreted as relative to the source of the context of the build.

Identique à COPY mais:

- Supporte les URLs
- Extrait les archives!



The CMD instruction has three forms:

- CMD ["executable", "param1", "param2"] (exec form, this is the preferred form)
- CMD ["param1","param2"] (as default parameters to ENTRYPOINT)
- CMD command param1 param2 (shell form)

There can only be one CMD instruction in a Dockerfile. If you list more than one CMD then only the last CMD will take effect.

The main purpose of a CMD is to provide defaults for an executing container. These defaults can include an executable, or they can omit the executable, in which case you must specify an ENTRYPOINT instruction as well.

ENTRYPOINT

ENTRYPOINT has two forms:

- ENTRYPOINT ["executable", "param1", "param2"] (exec form, preferred)
- ENTRYPOINT command param1 param2 (shell form)

An ENTRYPOINT allows you to configure a container that will run as an executable.

Un conteneur exécute: [ENTRYPOINT] [CMD]

WORKDIR

WORKDIR /path/to/workdir

The WORKDIR instruction sets the working directory for any RUN, CMD, ENTRYPOINT, COPY and ADD instructions that follow it in the Dockerfile. If the WORKDIR doesn't exist, it will be created even if it's not used in any subsequent Dockerfile instruction.

Exemple de Dockerfile

Alpine avec VIM

```
from alpine
RUN apk add vim
CMD ["vim"]
```

\$ docker build . -t alpvim

Sending build context to Docker daemon 3.072kB

Step 1/3 : from alpine ---> 055936d39205

Step 2/3 : RUN apk add vim ---> Running in 21c3189729ac

fetch http://dl-cdn.alpinelinux.org/alpine/v3.9/main/x86_64/APKINDEX.tar.gz fetch http://dl-cdn.alpinelinux.org/alpine/v3.9/community/x86_64/APKINDEX.tar.gz

(1/5) Installing lua5.3-libs (5.3.5-r2)

(2/5) Installing ncurses-terminfo-base (6.1_p20190105-r0)

(3/5) Installing neurses-terminfo (6.1_p20190105-r0)

(4/5) Installing ncurses-libs (6.1_p20190105-r0)

(5/5) Installing vim (8.1.1365-r0)

Executing busybox-1.29.3-r10.trigger

OK: 40 MiB in 19 packages

Removing intermediate container 21c3189729ac

---> e47638747864 Step 3/3 : CMD ["vim"]

---> Running in ac86ae31b7a3

Removing intermediate container ac86ae31b7a3

---> ee258ef6e23e

Successfully built ee258ef6e23e

Successfully tagged alpvim:latest

\$ docker run -ti alpvim

Ubuntu Serveur Web

from ubuntu

```
RUN apt-get update && \
apt-get install nginx -y && \
apt-get clean
```

EXPOSE 80/tcp

CMD ["nginx", "-g", "daemon off;"]

```
$ docker build . -t unginx
$ docker run -d -P --rm unginx
$ docker ps
```

CONTAINER ID IMAGE COMMAND CREATED STATUS PORTS NAMES 5dd75be0ed8a unginx "nginx -g 'daemon of..." 18 seconds ago Up 16 seconds 0.0.0.0:32771->80/tcp exciting_ride

Debian Serveur Web

from debian

```
RUN apt-get update && \
  apt-get install nginx -y && \
  apt-get clean
```

EXPOSE 80/tcp

CMD ["nginx", "-g", "daemon off;"]

```
$ docker build . -t unginx
$ docker run -d -P --rm unginx
$ docker ps
```

CONTAINER ID IMAGE 5dd75be0ed8a unginx

COMMAND

CREATED "nginx -g 'daemon of..." 18 seconds ago **STATUS** Up 16 seconds

PORTS

NAMES

0.0.0.0:32771->80/tcp exciting ride

La Composition De Conteneurs « docker-compose »

Considérons La Configuration Suivante



Comment démarrer deux conteneurs qui doivent partager des services ?

Docker Compose

docker-compose.yml

```
version: '3.3'

services:
    myredis:
    image: redis
    restart: always
    web:
        depends_on:
        - myredis
        image: mywebsebver
        ports:
        - « 8080:80"
        restart: always
        volumes:
        - ./html/:/var/www/html/
```

Syntaxe YAML!

https://fr.wikipedia.org/wiki/YAML

Serveur Web et Redis

```
version: '3.3'
                                         Conteneur base de donnée @ myredis
services:
  myredis.
    image: redis
    restart: always
  web:
    depends_on:
      - myredis
    image: mywebsebver
    ports:
                                                        Conteneur « web » @ web
      - « 8080:80"
    restart: always
    volumes:
           - ./html/:/var/www/html/
```

https://cheatography.com/tasjaevan/cheat-sheets/redis/

Redis

- Stockage clef-valeur avec des structure de donnée prédéfinies:
- → List
- → Hash
- → Sets
- **→** ...
- Liste de commandes : https://cheatography.com/tasjaevan/cheat-sheets/redis/
- Interface extrêmement simple:
- Via netcat 127.0.0.1 6379
- Via redis-cli (du paquet redis-tools)

Serveur Web et Redis

```
version: '3.3'
                                         Conteneur base de donnée @ myredis
services:
  myredis.
    image: redis
    restart: always
    ports:
                                    On expose le redis
      - "6379:6379"
   web:
    <del>depends on.</del>
      - myredis
                                                         Conteneur « web » @ web
    image: mywebsebver
    ports:
      - "8080:80"
    restart: always
    volumes:
            - ./html/:/var/www/html/
```